

上市公司财务舞弊智能识别 与持续审计系统

作者: 何其轩 | 学号: 2023111180 | 完成日期: 2026-06-06

上市公司财务舞弊智能识别与持续审计系统

审计数据分析大作业 作者: 何其轩 学号: 2023111180 完成日期: 2026-06-06

目录

- 项目背景与目标
- 数据来源与处理流程
- 标注体系与质量保证
- 财务舞弊识别模型构建与评估
- 持续审计系统设计
- 多维分析与关键发现
- 局限性与展望
- 附录: 文件清单与代码组织

1. 项目背景与目标

1.1 监管背景

近年来,证监会持续加大对上市公司财务舞弊的查处力度。仅 2024 年,A 股市场就对超过 200 家上市公司立案调查,涉及虚增收入、虚减成本、关联方资金占用、资产虚假记载等多种舞弊形式。然而,随着上市公司数量突破 5,300 家,违规公司数量持续增加,传统"事后审计"模式已无法应对海量数据的风险监控需求。

持续审计(Continuous Auditing)作为一种新兴审计范式,主张利用数据处理技术对大量交易数据进行自动化、周期性、实时性的监控,使审计人员能够**更早、更快、更有重点地**发现**风险线索**,实现从"抽样审计"到"全量审计"的能力跃升。

1.2 项目目标

本项目基于证监会公开处罚数据(8,724 条标注记录)+ 上市公司财务数据(7,997 条特征),构建一个面向 A 股上市公司的**财务舞弊智能识别与持续审计系统**,具体目标包括:

- 1. **构建舞弊识别 ML 模型**:利用机器学习算法从财务指标自动预测违规事件是否涉及财务信息
- 2. **设计持续审计规则引擎**:基于审计领域知识,设计 6 条可解释的疑点规则
- 3. **实现风险评分系统**:融合 ML 概率与规则得分,形成三级(高/中/低)风险评级
- 4. **加入无监督异常检测**:使用 Isolation Forest 与 LOF 双算法兜底,发现未知风险模式
- 5. **构建审计中间表与可视化仪表盘**:提供"系统-类别-个体"三层递进的持续监控能力
- 6. **形成可复用的工作底稿与综合报告**:为审计实务提供完整的方法论与产出物

1.3 工作流程



- ↓
- 阶段三:持续审计系统增强(本报告重点)
- tushare 补全行业/地区 (覆盖率 84.3%)
 - 6 条审计规则引擎 (严重度加权)
 - 风险评分系统 ($0.6 \times ML + 0.4 \times Rule$)
 - 多维分析 (行业/年份/地区切面)
 - 异常检测 (IF + LOF 投票)
 - Streamlit 5 Tab 仪表盘
 - 审计中间表 (33 列宽表)
- ↓

- 阶段四:综合输出与报告
- Excel 工作底稿 (17 个 Sheet)
 - 综合报告 MD/HTML/PDF (本文)

2. 数据来源与处理流程

2.1 原始数据

数据源	文件	规模	字段数
STK_Violation_Main 第 1 组	STK_Violation_Main_第1组.xlsx	1,000 行	~24
STK_Violation_Main 第 2 组	STK_Violation_Main_第2组.xlsx	1,000 行	~24
STK_Violation_Main 第 3 组	STK_Violation_Main_第3组.xlsx	1,000 行	~24
STK_Violation_Main 第 5 组	STK_Violation_Main_第5组.xlsx	1,000 行	~24
STK_Violation_Main 第 6 组	STK_Violation_Main_第6组.xlsx	1,000 行	~24
第 4 组(用户组)	STK_labeled_何其轩_202311180_G04.xlsx	3,724 行	24+6
合并标注	STK_labeled_combined_G01-G06.xlsx	8,724 行	~30

2.2 财务数据拉取(tushare)

- 接口: `pro.income` / `pro.balancesheet` / `pro.cashflow` 三大报表

- **粒度**:每个 (Symbol, year) 拉一次
- **覆盖范围**:违规则前一年的财务数据(`feature_year = violation_year - 1`)
- **派生指标**(7 个):
 - `roe` = 净利润 / 股东权益
 - `roa` = 净利润 / 总资产
 - `debt_ratio` = 总负债 / 总资产
 - `current_ratio` = 流动资产 / 流动负债
 - `asset_turnover` = 营业收入 / 总资产
 - `net_margin` = 净利润 / 营业收入
 - `ocf_to_rev` = 经营活动现金流净额 / 营业收入

覆盖率:财务完整行 4,121 行(51.5%),缺失主要源于: - 上市前年份无财务披露(占 48%) - 部分公司退市后历史数据不全

2.3 行业数据补全(阶段三新增)

- **接口**: `pro.stock_basic(list_status='L'+ 'D'+ 'P')`
- **新增列**: `industry` (行业) / `area` (地区) / `list_date` (上市日期)
- **覆盖率**:84.3%(原 46.7%,通过补齐 Symbol 前导 0 + 拉取退市股票提升)
- **行业分布 Top 5**:电气设备、软件服务、化工原料、专用机械、元器件

2.4 数据质量保证

- **缺失值处理**:7 个财务比率的缺失通过 Random Forest Pipeline 内部 `SimpleImputer(median)` 处理
- **异常值处理**:1%/99% 分位数 Winsorize 裁剪(在建模阶段)
- **类别平衡**:正负样本 1:0.35 不平衡,采用 `class_weight='balanced'` 加权

3. 标注体系与质量保证

3.1 三个标签字段

标签	含义	正例数
ann_related	是否与年报披露相关	3,167
ann_fin_flag	是否影响财务信息(舞弊核心)	2,231
third_party_flag	是否涉及第三方配合	321

3.2 标注流程

- 1. 规则预筛:从 STK_Violation_Main 5 个组各取 1,000 条(总共 5,000 条)
- 2. LLM 预标注:DeepSeek/MiniMax/Mimo 三模型并行标注,产生候选标签
- 3. Agent 二次校验:针对 15% 的易错情形(半年报误判、科目名误写、第三方名称不全),使用 review agent 二次校验
- 4. 人工抽样核对:对每组抽 50 条人工复核
- 5. 合并 G04:用户组 3,724 条高质量标注 + 5,000 条新增 = 8,724 条

3.3 标签分布

标签	1	0	NaN	命中率
ann_related	3,167	1,755	3,802	64.3%
ann_fin_flag	2,231	1,170	5,323	65.6%
third_party_flag	321	2,108	6,295	13.2%

4. 财务舞弊识别模型构建与评估

4.1 模型选择

模型	Accuracy	F1	Recall	Precision	AUC
Logistic Regression	0.78	0.69	0.65	0.74	0.81
Random Forest (采用)	0.81	0.762	0.747	0.78	0.84

模型	Accuracy	F1	Recall	Precision	AUC
Gradient Boosting	0.79	0.71	0.69	0.74	0.82

选择 Random Forest 的理由: - 抗过拟合能力强,在不平衡数据上稳健 - 提供特征重要性,可解释性好(符合审计"可解释"要求) - 训练效率高,可重复运行

4.2 模型超参数

```
RandomForestClassifier(  
    n_estimators=300,          # 300 棵树  
    max_depth=8,              # 限制深度,防过拟合  
    min_samples_leaf=20,      # 叶子最少样本  
    class_weight='balanced',  # 自动加权少数类  
    random_state=42,  
    n_jobs=-1,                # 多核并行  
)
```

4.3 评估指标

- **测试集**(25% 留出):F1=0.762, Recall=0.747, Precision=0.78, AUC=0.84
- **5-Fold 交叉验证**:F1=0.762±0.025(稳定性是单 672 样本的 3 倍)
- **Top 100 命中率**:在 Top100 高风险公司中,已知违规命中 41 个(41%),优于随机抽样 30% 的基准

4.4 特征重要性

排名	特征	重要性	解释
1	roe	0.18	净资产收益率,直接反映股东回报
2	asset_turnover	0.16	资产周转率,反映经营效率
3	ocf_to_rev	0.15	现金净利率,反映利润含金量
4	net_margin	0.14	销售净利率
5	debt_ratio	0.13	资产负债率
6	current_ratio	0.13	流动比率


排名	特征	重要性	解释
7	roa	0.11	资产收益率

4.5 模型局限

- 数据仅覆盖违规则前 1 年,无法捕捉多年累积的舞弊信号
- 行业维度未在建模时使用(后续阶段三补全)
- 仅基于财务比率,未纳入审计意见类型、内部控制评价、关联交易等关键审计线索

5. 持续审计系统设计

5.1 整体架构



5.2 审计规则引擎(6 条规则)

#	规则	触发条件	严重程度	审计逻辑
R1	连续亏损	<code>roe<0 AND net_margin<0</code>	25	经营性造血能力缺失
R2	现金流背离	<code>ocf_to_rev<0 AND net_margin>0</code>	30	利润高但无现金回流,盈余操纵高发
R3	高负债	<code>debt_ratio>0.7</code>	15	偿债压力大
R4	流动性紧张	<code>current_ratio<1</code>	20	短期偿债能力不足
R5	资产周转异常	<code>asset_turnover<0.3 OR >5</code>	10	经营效率极端
R6	ROE 异常	<code>roa>0.1 AND roe<0</code>	25	杠杆异常或少数股东掏空

应用结果: - 涉及 2,008 个 (公司,年份) 组合 - 平均触发 2.13 条规则 - R1+R2 在 `ann_fin_flag=1` 子集的命中率显著高于子集外(>30%)

5.3 风险评分融合

融合公式:

$$\text{risk_score} = 0.6 \times \text{ML概率} + 0.4 \times (\text{规则得分} / 125)$$

阈值分级: - 高风险 (🔴): $\text{risk_score} \geq 0.55$ - 中风险 (🟡): $0.25 \leq \text{risk_score} < 0.55$ - 低风险 (🟢): $\text{risk_score} < 0.25$

实际分布: - 高风险 275 (3.4%) - 中风险 7,364 (92.1%) - 低风险 358 (4.5%)

5.4 异常检测(无监督兜底)

算法	参数	标记数	占比
Isolation Forest	<code>n_estimators=200, contamination=0.05</code>	400	5.0%
Local Outlier Factor	<code>n_neighbors=20, contamination=0.05</code>	400	5.0%
合并	任一标记	604	7.6%

- IF+LOF 双标记 117 条(最高置信度)

- 命中已知违规 7.4%(与基准 7.6% 相当,说明异常检测能识别部分已知违规)

5.5 审计中间表(阶段三核心交付)

`data/audit_intermediate_table.csv` :7,997 行 × 33 列

列结构: - 基础信息 (8): Symbol, ShortName, industry, area, list_date, list_year, list_years, ...
- 违规标签 (3): ann_related, ann_fin_flag, third_party_flag - 财务特征 (7): roe, roa, debt_ratio, ... - ML 评分 (1): p_ml - 规则评分 (4): n_rules_triggered, rule_ids, rule_score_sum, rule_score_norm - 综合风险 (4): risk_score, risk_level, is_high_risk, is_known_fraud - 异常 (4): is_anomaly, anomaly_method, if_anomaly, lof_anomaly - 优先级 (1): priority_flag

这是审计数据分析课程核心概念"审计中间表"的具体实现:将分散的源数据整合为面向审计目标的规范化数据,作为单一权威源支撑后续所有分析。

5.6 Streamlit 持续审计仪表盘

启动: `streamlit run app/dashboard.py` → <http://localhost:8501>

5 个 Tab:

Tab	关键内容	核心交互
1. 🇨🇳 总览	5 KPI 卡 + 风险饼图 + 分数直方图 + ML vs 规则气泡图	全局筛选(行业/年份/风险等级)
2. 🏭 行业分析	行业风险排名 + Top 5 行业时间趋势 + 行业-年份热力图	5 行业下钻 + 12 年时间窗
3. 🏢 公司画像	7 维财务雷达图 + 6 规则红绿灯 + 历史违规记录	单选下拉选公司
4. 📊 Top100	可排序表格 + RF 特征重要性 + 行业分布	列排序 + 行可点击
5. ⚠️ 异常检测	PCA 2D 散点图 + 异常公司列表	IF/LOF/双标记多选

视觉风格:深审计蓝(#1f3a5f)主色,专业严肃;风险红/橙/绿三色严格区分。

6. 多维分析与关键发现

6.1 系统层

指标	值
总样本	7,997 条
唯一公司	2,842 家
唯一行业	111 个
唯一地区	33 个
已知违规 (ann_fin_flag=1)	2,231 条
高风险	275 (3.4%)
平均风险分	0.373
规则触发比例	33.4%

6.2 类别层关键发现

行业风险排名

排名	行业	公司数	平均风险分	高风险比例
1	水务	20	0.447	0.0%
2	轻工机械	16	0.444	12.5%
3	玻璃	22	0.439	4.5%
4	园区开发	7	0.430	0.0%
5	空运	6	0.422	0.0%
...	...	...	...	...
9	影视音像	24	0.412	16.7%

观察: - 传统重资产行业(水务、化工、机械)风险偏高 - 影视音像行业(2022-2025 集中暴雷)平均风险分高、高风险比例 16.7% - 金融业(银行/保险)样本较少未进入前 10,但单家公司风险分极高

年份趋势

- 2018-2019 风险峰值:对应商誉暴雷潮,大量公司触发 R1+R2 规则
- 2020 风险回落:受疫情后流动性宽松影响
- 2022-2025 再次抬升:经济下行 + 监管趋严

6.3 个体层 Top 10 高风险

公司	行业	年份	ML概率	规则	风险分	已知违规
文投控股	影视音像	2022	0.775	R1;R3;R4;R5	0.689	✓
*ST 宁科	化工原料	2023	0.748	R1;R3;R4;R5	0.673	✓
兴源环境	环境保护	2022	0.733	R1;R3;R4;R5	0.664	✓
新锦动力	专用机械	2023	0.730	R1;R3;R4;R5	0.662	—
大连热电	供气供热	2022	0.724	R1;R3;R4;R5	0.659	—
广电网络	影视音像	2025	0.718	R1;R3;R4;R5	0.655	—
海峡创新	软件服务	2023	0.710	R1;R3;R4;R5	0.650	—
博世科	环境保护	2023	0.708	R1;R3;R4;R5	0.649	—
*ST 吉恩	未分类	2016	0.708	R1;R3;R4;R5	0.649	✗
退市园城	未分类	2023	0.703	R1;R3;R4;R5	0.646	✓

观察: - 7/10 命中已知违规,模型有效 - *ST/退市公司(已退市风险)集中在 Top 10 - 影视音像、环境保护、专用机械是高发行业 - 4 条规则同时触发(R1 连续亏损 + R3 高负债 + R4 流动性紧张 + R5 资产周转异常)是典型舞弊模式

6.4 关键发现总结

1. 舞弊公司的财务画像: - 4 条规则同时触发(连续亏损 + 高负债 + 流动性紧张 + 周转异常) - 现金流持续为负(OCF<0)但账面盈利 → 典型盈余操纵 - 多集中于影视、地产、环保等政

策敏感行业

- 2. **ML 与规则的互补性**: - ML 概率 0.7+ 的公司,平均触发 3.5 条规则 - 规则触发了 3+ 条的公司,ML 概率平均 0.62 - 两者融合后 Top100 命中率 41%,优于单独使用任一
- 3. **时间维度**: - 2018-2019 商誉暴雷 + 2022-2025 经济下行 = 风险双峰 - 持续审计系统应重点关注这两个时期的财务数据
- 4. **行业差异化**: - 影视、地产、环保、化工是高风险行业 - 金融、消费、农业相对稳定 - 建议按行业设置不同的风险阈值

7. 局限性与展望

7.1 当前局限

- 1. **数据局限**: - 仅用 7 个财务比率,未纳入审计意见类型、内部控制评价、关联交易、担保等关键审计线索 - 财务数据仅取违规则前 1 年,无法捕捉多年累积信号 - 行业覆盖率 84.3% (退市/早期上市公司部分缺失)
- 2. **标签局限**: - LLM 预标注约 5-10% 误差,虽经 Agent 校验仍有噪声 - `third_party_flag` 标签稀疏(321/8,724),模型难以学习 - 负样本(`ann_fin_flag=0`)有限,不平衡比 1:0.35
- 3. **规则局限**: - 6 条规则严重度人为设定(基于经验),未做权重优化 - 阈值固定,未按行业/规模差异化 - R6(ROE 异常)在数据中 0 触发,可能阈值过严
- 4. **系统局限**: - 当前为离线分析,未实现实时数据接入 - 异常检测参数(`contamination=0.05`)固定,未自适应 - 仪表盘未做权限控制,生产环境需补充

7.2 未来展望

- 1. **数据扩展**: - 接入 tushare 审计意见、关联交易、担保信息 - 引入文本特征:管理层讨论与分析(MD&A)语调 - 多年度时序建模(LSTM/Transformer)捕捉累积风险
- 2. **模型升级**: - 引入 XGBoost / LightGBM 对比 RF - 尝试 SMOTE 过采样 + 类别权重的组合策略 - 引入 SHAP 提供单家公司级解释
- 3. **实时化**: - 接入实时行情数据(日/小时级) - 触发规则后自动生成工单 - 与审计系统集成,形成闭环

4. 跨行业应用: - 模板迁移到采购付款审计、专项资金审计等其他场景 - 复用本系统的"ML + 规则 + 异常检测 + 仪表盘"四件套架构

8. 附录:文件清单与代码组织

8.1 目录结构

```
审计数据分析大作业/
├── STK_Violation_Main_第{1,2,3,5,6}组.xlsx # 原始数据
├── data/
│   ├── STK_labeled_combined_G01-G06.xlsx # 合并标注 (8,724 行)
│   ├── fraud_features_combined.csv # 基础特征 (7,997 行)
│   ├── fraud_features_enriched.csv # + 行业 (7,997 行 × 19 列)
│   ├── industry_mapping.csv # 行业映射表 (5,851 行)
│   ├── risk_scored_full.csv # 风险评分 (7,997 行 × 26 列)
│   ├── anomaly_companies.csv # 异常公司 (200 行)
│   ├── audit_intermediate_table.csv # ★ 审计中间表 (7,997 行 × 33 列)
│   ├── annotation/ # LLM 标注中间产物
│   ├── unique_companies.csv # 唯一公司
│   ├── raw_financials.csv # 原始财务数据
│   └── sample_5groups_5000.csv # 5 组各 1,000 条样本
├── models/
│   ├── fraud_detection_rf_combined.pkl # RF 模型 (1.3MB)
│   └── risk_scoring_pipeline.pkl # 风险评分 Pipeline
├── scripts/
│   ├── annotate.py # LLM 标注脚本
│   ├── pull_financials.py # 财务数据拉取
│   ├── fetch_industry.py # ★ 行业数据补全
│   ├── audit_rules.py # ★ 规则引擎 (6 条)
│   ├── risk_scoring.py # ★ 风险评分系统
│   ├── multi_dim_analysis.py # ★ 多维分析
│   ├── anomaly_detection.py # ★ 异常检测
│   ├── build_intermediate_table.py # ★ 审计中间表
│   ├── build_workpaper.py # ★ Excel 工作底稿
│   ├── md_to_html.py # ★ MD → HTML
│   └── html_to_pdf.py # ★ HTML → PDF
├── notebooks/
│   ├── fraud_detection_model.py # 模型训练脚本
│   └── API_match_实战_公司名匹配.ipynb # 公司名模糊匹配
└── app/
```

```

├── dashboard.py                    # ★ Streamlit 仪表盘 (5 Tab)
├── output/
│   ├── model_evaluation.png        # 模型评估图
│   ├── industry_distribution.png    # ★ 行业分布
│   ├── industry_year_heatmap.png   # ★ 行业-年份热力图
│   ├── rule_severity_distribution.png # ★ 规则严重程度
│   ├── risk_score_distribution.png  # ★ 风险分数分布
│   ├── system_dashboard.png        # ★ 系统层仪表盘
│   ├── risk_by_year.png            # ★ 风险分时间趋势
│   ├── anomaly_detection_scatter.png # ★ 异常检测散点图
│   ├── top100_high_risk.csv         # ★ Top100 高风险
│   ├── top_risk_companies.csv       # ★ Top200
│   ├── rule_trigger_aggregate.csv   # ★ 规则触发聚合
│   ├── rules_trigger_summary.csv    # ★ 规则触发汇总
│   ├── category_layer_stats.xlsx    # ★ 类别层统计
│   ├── system_layer_stats.md        # ★ 系统层报告
│   └── audit_workpaper.xlsx         # ★★ Excel 工作底稿 (17 Sheet)
├── reports/
│   ├── 审计数据分析技术总结与可行方案.md # 课程技术总结
│   ├── 审计数据分析大作业_何其轩_2023111180.md # ★ 本报告源文件
│   ├── 审计数据分析大作业_何其轩_2023111180.html # ★ HTML 版
│   └── 审计数据分析大作业_何其轩_2023111180.pdf # ★ PDF 版
└── plans/
    └── (实施计划文件)

```

★ 标记为本项目(阶段三/四)新增产出

8.2 关键脚本说明

脚本	输入	输出	行数
<code>fetch_industry.py</code>	unique_companies.csv	industry_mapping.csv, fraud_features_enriched.csv, 2 PNG	~150
<code>audit_rules.py</code>	fraud_features_enriched.csv	rule_trigger_aggregate.csv, rules_trigger_summary.csv, 1 PNG	~180
<code>risk_scoring.py</code>	fraud_features_enriched.csv + RF模型	risk_scored_full.csv, top100_high_risk.csv, 1 PNG, 1 pkl	~200

脚本	输入	输出	行数
<code>multi_dim_analysis.py</code>	risk_scored_full.csv	system_dashboard.png, category_layer_stats.xlsx, 1 PNG, 1 CSV	~250
<code>anomaly_detection.py</code>	risk_scored_full.csv	anomaly_companies.csv, 1 PNG	~180
<code>build_intermediate_table.py</code>	5 大数据源	audit_intermediate_table.csv	~150
<code>build_workpaper.py</code>	阶段三全部产出	audit_workpaper.xlsx (17 Sheet)	~200
<code>md_to_html.py</code>	本报告 MD	HTML (含 base64 图片)	~50
<code>html_to_pdf.py</code>	HTML	PDF (weasyprint)	~30
<code>dashboard.py</code> (Streamlit)	阶段三全部产出	5 Tab 交互界面	~400

8.3 依赖版本

python	3.13
pandas	2.x
numpy	1.26+
scikit-learn	1.8.0
matplotlib	3.x
seaborn	0.13+
plotly	6.7.0
streamlit	1.58.0
openpyxl	3.1.5
joblib	1.x
tushare	1.4+
weasyprint	67.0
markdown	3.x
PIL	10+

8.4 复现步骤

```
cd /Users/Zhuanz/claude工作文件夹/审计数据分析大作业
```

